# Punto 3. Base de datos de comparación

Una fuente externa para comprobar si nuestras alertas tienen sentido

## 1. Qué nos pidieron

El punto dice: *«Base de datos de comparación: buscar una fuente externa que nos permita contrastar los resultados para un futuro modelo. En caso de no encontrarla, revisar en la literatura otras alternativas metodológicas».*

La razón viene de la revisión con el profesor. Nuestro índice marca un contrato como alerta cuando se cumplen dos de tres señales, y esa regla la definimos nosotros. El profesor señaló que no podemos ser «juez y parte»: si después entrenamos un modelo con alertas que definimos nosotros, el modelo solo aprende nuestra propia regla. Para que el ejercicio sea real necesitamos una contraparte externa que diga qué casos son realmente problemáticos.

## 2. En una frase

Encontramos esa contraparte externa: dos bases públicas de sanciones a contratistas y responsables fiscales, publicadas por entidades del Estado y disponibles en el portal PACO, que podemos unir con nuestros contratos por el número de documento del proveedor.

## 3. Dónde están: el portal PACO

PACO es la Plataforma Anticorrupción de Colombia, de la Secretaría de Transparencia de la Presidencia de la República (s. f.). No crea los datos: reúne bases de otras entidades públicas (Procuraduría, Contraloría, Fiscalía, SECOP, Superintendencia de Industria y Comercio) y las deja descargar en formatos como CSV y Excel. Revisamos las que podían relacionarse con contratación y descargamos tres.

**Tabla 1**

*Bases externas revisadas*

| Base | Quién la publica | Qué contiene | ¿La usamos? |
|---|---|---|---|
| Multas y sanciones contractuales | SECOP (Colombia Compra Eficiente) | 1.721 registros, de 2010 a 2024 | Sí |
| Responsabilidades fiscales | Contraloría General de la República | 5.961 registros de 5.062 documentos distintos | Sí |
| Sanciones disciplinarias | Procuraduría General de la Nación (SIRI) | 46.584 registros, solo 16 de contratistas | No |

Nota. Conteos calculados sobre los archivos descargados de PACO en octubre de 2026.

**4. Qué es cada base, en palabras simples**

**Multas y sanciones contractuales.** Cuando un contratista incumple un contrato con el Estado, la entidad puede ponerle una multa o sanción. Esta base es la lista de esas multas. Cada fila dice qué entidad sancionó (con su NIT), a quién (documento y nombre del contratista), en qué contrato (referencia), por cuánto (monto) y cuándo (fecha). Tiene 1.721 filas, la mayoría entre 2014 y 2022, y los enlaces llevan a SECOP I, la versión anterior de la plataforma.

**Responsabilidades fiscales.** Es el Boletín de Responsables Fiscales de la Contraloría General de la República. Lista a las personas y empresas que la Contraloría declaró responsables de haber causado un daño al patrimonio público. Cada fila trae el nombre, el tipo y número de documento, la entidad afectada, quién reporta, el departamento y el municipio. Tiene 5.961 filas que corresponden a 5.062 documentos distintos (algunos responsables aparecen en varios casos). No trae número de contrato ni fecha.

**Sanciones disciplinarias (la descartamos).** Viene del SIRI de la Procuraduría y registra sanciones a personas. De sus 46.584 filas, 28.445 son miembros de la fuerza pública, 17.826 servidores públicos, 165 particulares que ejercen funciones públicas y solo 16 contratistas. Como casi todos son funcionarios y no proveedores, no sirve para contrastar contratos.

**5. Cómo se conectan con nuestro trabajo**

Piénsalo como una lista de «proveedores con antecedentes». Cada contrato nuestro tiene un proveedor con su número de documento. Si ese número aparece en una de las dos bases, el contrato queda marcado como «proveedor sancionado». Con esa marca podemos hacer dos cosas:

- **Justificar las alertas:** comparar qué porcentaje de contratos con alerta tiene un proveedor sancionado frente a los contratos sin alerta.
- **Tener una respuesta externa para un modelo:** la marca «proveedor sancionado» la definió otra autoridad, no nuestra fórmula.

**6. Cumplimiento de lo que pide el profesor**

| **Por qué cumple con lo que pide el profesor** |
|---|

**1. Es externa.** Las sanciones las deciden entidades del Estado (las entidades contratantes y la Contraloría), no nosotros. Así dejamos de ser «juez y parte»: la alerta la define nuestra regla, pero la prueba contra la que la comparamos viene de otra autoridad.

**2. Se puede relacionar con nuestros datos.** Las dos bases identifican a la persona o empresa con su número de documento. Nuestra tabla de contratos de SECOP II tiene el «Documento Proveedor» (Agencia Nacional de Contratación Pública, 2026). Con ese número se puede saber si el proveedor de un contrato aparece sancionado.

**3. Permite justificar las alertas.** Si nuestro índice funciona, entre los contratos con alerta debería haber más proveedores sancionados que entre los contratos sin alerta. Esa comparación es el contraste que se nos pide.

**4. Sirve para un futuro modelo.** El profesor dijo que, para entrenar un modelo, «alguien externo» debe decir qué es fraude y el modelo debe usar variables distintas a las que definen la alerta. La marca «proveedor sancionado» es esa información externa, y las tres señales (concentración, valor atípico y diciembre) quedarían como variables del modelo y no como su respuesta.

**5. Hay una alternativa en la literatura.** Por si la fuente externa no bastara, la sección 7 presenta cinco rutas publicadas para validar un índice de riesgo.

## 7. Alternativas en la literatura

El problema no es exclusivo de nuestro proyecto: casi nunca existe una lista confiable de contratos corruptos para comparar. La literatura ofrece varias rutas para validar un índice de riesgo. Estas cinco son independientes entre sí y cada una se puede usar sola.

**7.1 Revisar si los indicadores son coherentes entre sí.** Gnaldi y Del Sarto (2023) descartaron las sentencias judiciales como referencia porque son pocas, llegan tarde y son difíciles de conseguir. En su lugar aplicaron un método estadístico a 15 indicadores de unas 7.900 entidades contratantes con licitaciones italianas de 2017, para ver si miden una misma idea de riesgo. Tres indicadores casi no se relacionaban con el resto y los trataron como débiles. Para nosotros equivale a revisar si concentración, valor atípico y diciembre aportan información distinta o se repiten, y si alguna señal casi no aporta.

**7.2 Comparar con otros síntomas de corrupción.** Fazekas et al. (2016) construyeron un índice con datos de contratación pública de Hungría y lo validaron comparándolo con señales que se esperarían si hubiera corrupción. Las empresas con puntaje de riesgo más alto tenían mayor

rentabilidad, un mayor cociente entre el valor del contrato y el precio estimado inicial, más probabilidad de estar administradas o ser propiedad de políticos y más probabilidad de estar registradas en paraísos fiscales. En SECOP II se puede hacer algo parecido con variables propias de la plataforma, por ejemplo las adiciones al valor o al plazo del contrato, y revisar si los contratos en alerta las tienen con más frecuencia.

**7.3 Usar los resultados del contrato como referencia.** Gallego et al. (2021) trabajaron con más de dos millones de contratos públicos de Colombia y entrenaron modelos para anticipar cuáles contratos terminarían en investigaciones por corrupción, incumplimientos del contrato o ineficiencias en la ejecución. La idea que se rescata es que la referencia no tiene que ser una condena: un incumplimiento o una sanción posterior también es un resultado observable. Esto es lo que representa la base de multas y sanciones contractuales de PACO.

**7.4 Comparar con un índice ya publicado para Colombia.** Zuleta et al. (2019) y Zuleta y Caro (2020) calcularon para el sistema de compra pública colombiano un índice de riesgo de corrupción con la metodología del Instituto Mexicano para la Competitividad (IMCO) y analizaron las alertas que resultan. Esas alertas son un punto de comparación para ver si nuestras señales identifican contratos y entidades parecidas a las de un índice publicado por el Banco Interamericano de Desarrollo y Fedesarrollo.

**7.5 Etiquetar a mano una muestra con una persona externa.** Figueroa-Gómez y Galpin (2024) etiquetaron manualmente una muestra de licitaciones de SECOP II para entrenar y comparar modelos de clasificación. Su objetivo era otro (identificar licitaciones de interés para una universidad), pero el procedimiento es el mismo: una persona que no definió la regla revisa una muestra y decide cuáles casos son de riesgo, y ese juicio se compara con las alertas del índice.

## 8. Lo que hay que tener en cuenta

- Que un proveedor no tenga sanción no quiere decir que esté limpio, solo que nadie lo sancionó. Por eso el resultado es un contraste y no una prueba de fraude.
- Las bases se unen por proveedor y no por contrato: todos los contratos de un proveedor sancionado quedan marcados.

- La base de multas es de SECOP I y la de responsabilidades fiscales no tiene fechas, así que la comparación es por proveedor, sin ordenar los hechos en el tiempo.
- Este documento presenta la fuente y su justificación. No incluye resultados numéricos de la comparación con las alertas.

**Referencias**

Agencia Nacional de Contratación Pública – Colombia Compra Eficiente. (2026). *Diccionario de datos de registros administrativos* [Documento técnico]. https://www.colombiacompra.gov.co/wp-content/uploads/2026/01/Diccionario_de_Datos_RegistrosAdministrativos-1.pdf

Fazekas, M., Tóth, I. J., & King, L. P. (2016). An objective corruption risk index using public procurement data. *European Journal on Criminal Policy and Research, 22*(3), 369–397. https://doi.org/10.1007/s10610-016-9308-z

Figueroa-Gómez, Y., & Galpin, I. (2024). Identifying public tenders of interest using classification models: A comparative analysis. *SN Computer Science, 5*, Artículo 87. https://doi.org/10.1007/s42979-023-02443-3

Gallego, J., Rivero, G., & Martínez, J. (2021). Preventing rather than punishing: An early warning model of malfeasance in public procurement. *International Journal of Forecasting, 37*(1), 360–377. https://doi.org/10.1016/j.ijforecast.2020.06.006

Gnaldi, M., & Del Sarto, S. (2023). *Validating corruption risk measures: A key step to monitoring SDG progress* [Preprint]. arXiv. https://arxiv.org/abs/2309.01462

Secretaría de Transparencia de la Presidencia de la República. (s. f.). *Bases de datos* [Portal PACO]. Recuperado el 20 de octubre de 2026, de https://portal.paco.gov.co/index.php?pagina=descargarDatos

Zuleta, M. M., & Caro, C. A. (2020). *Mirada a las alertas del índice de riesgo de corrupción del sistema de compra pública colombiano identificadas en el cálculo del índice con la metodología del IMCO*. Banco Interamericano de Desarrollo.

Zuleta, M. M., Ospina, S., & Caro, C. A. (2019). *Índice de riesgo de corrupción en el sistema de compra pública colombiano a partir de una metodología desarrollada por el Instituto Mexicano para la Competitividad*. Banco Interamericano de Desarrollo; Fedesarrollo.